

SERVICIO NACIONAL DE APRENDIZAJE - SENA

Programa: Procesamiento de Datos para Modelos de Inteligencia Artificial

Proyecto formativo: Construcción de datasets para ser empleados en modelos de IA

GUÍA DE APRENDIZAJE COMPLETA

Codificación de variables categóricas, escalamiento numérico y preparación de datasets para modelos de IA

Periodo: mayo y junio de 2026

Duración: 120 horas - 3 encuentros semanales de 5 horas

1. Identificación general de la guía

Elemento	Descripción
Programa	Procesamiento de Datos para Modelos de Inteligencia Artificial
Nivel	Técnico
Fase del proyecto	Ejecución - preparación de datasets para entrenamiento y evaluación
Duración	120 horas
Periodo	Mayo y junio de 2026
Intensidad	3 días por semana - 5 horas por encuentro
Producto integrador	Dataset preparado, codificado, escalado, segmentado, documentado y sustentado
Herramientas	Python, pandas, NumPy, scikit-learn, Google Colab o Jupyter Notebook

2. Justificación pedagógica y técnica

Después de estudiar transformación y limpieza de datos, el aprendiz debe avanzar hacia la preparación técnica del dataset para modelos de inteligencia artificial. Un dataset limpio puede tener valores correctos y formatos consistentes, pero aún no estar listo para IA si contiene categorías en texto, variables numéricas en escalas incompatibles, identificadores como predictores o transformaciones aplicadas antes de separar entrenamiento y prueba.

Esta guía fortalece el criterio técnico del aprendiz para decidir qué variable se codifica, qué variable se escala, qué variable se excluye y cómo se documenta el proceso. La guía no se centra en entrenar modelos avanzados, sino en preparar datos de manera reproducible para que puedan ser usados por un modelo de IA.

3. Competencias y resultados de aprendizaje relacionados

Competencia	Resultados asociados
Integrar datos según técnicas de visualización y metodologías de análisis	Preparar datos según fuentes de información; alistar datos para una solución IA; procesar datos de acuerdo con procedimiento técnico; presentar datos mediante visualización.
Sistematizar datos masivos de acuerdo con métodos de analítica y herramientas tecnológicas	Preparar datasets para entrenamiento y evaluación según el modelo de IA a emplear; documentar el proceso de acuerdo con procedimientos de la organización.

4. Problema formativo

Una organización tiene un dataset de clientes ya limpiado. Sin embargo, el equipo de analítica detecta que todavía no puede ser usado por un modelo de inteligencia artificial porque contiene variables categóricas nominales en texto, una variable ordinal, variables numéricas con rangos diferentes, posibles valores extremos, un identificador de cliente y una variable objetivo binaria. El aprendiz debe preparar el dataset final, justificar cada transformación y entregar evidencias técnicas.

5. Pregunta orientadora

¿Cómo preparar técnicamente un dataset limpio para que pueda ser utilizado en el entrenamiento y evaluación de un modelo de inteligencia artificial, aplicando codificación de variables categóricas, escalamiento de variables numéricas y separación adecuada de los datos?

6. Objetivos de aprendizaje

- Clasificar variables según su naturaleza: numéricas, nominales, ordinales, identificadoras y objetivo.

- Aplicar codificación dummy, One-Hot Encoding y codificación ordinal según corresponda.
- Aplicar y comparar MinMaxScaler, StandardScaler y RobustScaler.
- Seleccionar el escalador adecuado según rangos, dispersión y valores extremos.
- Separar datos en entrenamiento y prueba antes de ajustar transformadores.
- Evitar fuga de información aplicando correctamente fit_transform y transform.
- Construir un flujo reproducible con ColumnTransformer y Pipeline.
- Exportar datasets preparados y documentar el proceso completo.

7. Saberes requeridos

Dimensión	Descripción
Saber conocer	Tipos de variables; codificación nominal y ordinal; escalamiento; entrenamiento/prueba; fuga de información; pipeline; documentación técnica.
Saber hacer	Cargar datos, clasificar columnas, codificar variables, escalar variables, separar train/test, construir ColumnTransformer, exportar CSV e informe.
Saber ser	Rigor técnico, responsabilidad, pensamiento crítico, ética de datos, orden en el código, trabajo colaborativo y claridad al sustentar.

8. Dataset base sugerido para la guía

Para la demostración y práctica se suministra un dataset limpio de clientes con variables numéricas, nominales, ordinales, identificadoras y una variable objetivo. El instructor puede reemplazarlo por otro dataset siempre que conserve los mismos retos técnicos.

Variable	Descripción	Tipo	Tratamiento recomendado
ID_Cliente	Identificador único del cliente	Categórica identificadora	Excluir del modelo
Edad	Edad del cliente en años	Numérica discreta	Escalamiento estándar
IngresoMensual	Ingreso mensual estimado del cliente	Numérica continua	Escalamiento robusto por posibles valores extremos
CantidadCompras	Número histórico de compras	Numérica discreta	Escalamiento estándar
Ciudad	Ciudad principal del cliente	Categórica nominal	One-Hot Encoding
Genero	Género reportado por el cliente	Categórica nominal	One-Hot Encoding
Segmento	Segmento comercial del cliente	Categórica nominal	One-Hot Encoding
NivelSatisfaccion	Nivel de satisfacción reportado	Categórica ordinal	Codificación ordinal: Bajo < Medio < Alto
AntigüedadMeses	Meses de antigüedad del cliente	Numérica discreta	Escalamiento estándar
DiasUltimaCompra	Días desde la última compra	Numérica discreta	Escalamiento estándar
GastoPromedio	Gasto promedio del cliente	Numérica continua	Escalamiento robusto por posibles valores extremos
CanalPreferido	Canal principal de interacción	Categórica nominal	One-Hot Encoding
Compra	Variable objetivo: 1 compró, 0 no compró	Binaria objetivo	No transformar como predictora

9. Cronograma general de trabajo

Semana	Fechas	Horas	Tema	Evidencia principal
1	4, 6 y 8 mayo	15 h	Del dato limpio al dataset preparado para IA	Diagnóstico y diccionario de variables
2	11, 13 y 15 mayo	15 h	Codificación de variables categóricas nominales	Notebook de codificación nominal
3	18, 20 y 22 mayo	15 h	Codificación ordinal y alta cardinalidad	Notebook avance 1
4	25, 27 y 29 mayo	15 h	Escalamiento numérico	Comparación de escaladores
5	1, 3 y 5 junio	15 h	RobustScaler y selección de escalador	Matriz de decisión técnica
6	8, 10 y 12 junio	15 h	Train/test split y fuga de información	Notebook avance 2
7	15, 17 y 19 junio	15 h	ColumnTransformer, Pipeline y exportación	Datasets preparados
8	22, 24 y 26 junio	15 h	Informe, validación y socialización	Entrega final completa

10. Planeación detallada por sesión

Sesión 1 - 4 mayo: ¿Qué significa preparar datos para IA?

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Presentar producto final; revisar dataset; identificar variable objetivo e identificadores.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Tabla inicial de variables.

Sesión 2 - 6 mayo: Tipos de variables y decisiones de preprocesamiento

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Clasificar variables: nominal, ordinal, numérica, identificadora y objetivo.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Diccionario de variables.

Sesión 3 - 8 mayo: Diagnóstico técnico antes de codificar

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Revisar tipos, rangos, valores únicos y columnas a transformar.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Diagnóstico técnico.

Sesión 4 - 11 mayo: Error de asignar números arbitrarios

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Analizar por qué Ciudad=1, Cali=2 crea falsa jerarquía.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Miniinforme de error común.

Sesión 5 - 13 mayo: Variables dummy con pandas

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Aplicar pd.get_dummies y analizar columnas generadas.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Ejercicio dummy.

Sesión 6 - 15 mayo: One-Hot Encoding profesional

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Aplicar OneHotEncoder y handle_unknown=ignore.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Notebook One-Hot.

Sesión 7 - 18 mayo: Codificación ordinal

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Codificar NivelSatisfaccion respetando jerarquía.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Tabla ordinal original/codificada.

Sesión 8 - 20 mayo: Alta cardinalidad

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Contar categorías, analizar columnas generadas y agrupar categorías raras.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Análisis de cardinalidad.

Sesión 9 - 22 mayo: Taller integrador de codificación

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Integrar nominales y ordinales en un avance de notebook.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Notebook avance 1.

Sesión 10 - 25 mayo: Concepto de escalamiento

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Comparar Edad, IngresoMensual y GastoPromedio; revisar rangos.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Tabla estadística.

Sesión 11 - 27 mayo: MinMaxScaler

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Normalizar variables a rango 0-1 y analizar resultados.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Notebook MinMax.

Sesión 12 - 29 mayo: StandardScaler

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Estandarizar variables con media 0 y desviación 1.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Comparación MinMax/Standard.

Sesión 13 - 1 junio: Valores extremos

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Identificar outliers mediante estadísticos y boxplots.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Diagnóstico de outliers.

Sesión 14 - 3 junio: RobustScaler

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Aplicar escalamiento robusto en variables con outliers.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Notebook RobustScaler.

Sesión 15 - 5 junio: Selección del escalador

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Construir matriz de decisión por variable.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Matriz técnica.

Sesión 16 - 8 junio: Separación entrenamiento/prueba

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Separar X/y y train/test con stratify cuando aplique.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Conjuntos separados.

Sesión 17 - 10 junio: Fuga de información

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Diferenciar fit_transform en train y transform en test.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Explicación escrita.

Sesión 18 - 12 junio: Taller integrado sin fuga

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Aplicar codificación y escalamiento después del split.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Notebook avance 2.

Sesión 19 - 15 junio: ColumnTransformer

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Configurar transformaciones por tipo de columna.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Preprocesador funcional.

Sesión 20 - 17 junio: Pipeline reproducible

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Integrar preprocesador y modelo simple de verificación.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Pipeline ejecutable.

Sesión 21 - 19 junio: Exportación de datasets

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Crear dataset_train_preparado y dataset_test_preparado.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	CSV preparados.

Sesión 22 - 22 junio: Informe técnico

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Redactar introducción, dataset, técnicas y conclusiones.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Borrador de informe.

Sesión 23 - 24 junio: Validación técnica

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Aplicar lista de chequeo y ajustar errores.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Lista de chequeo.

Sesión 24 - 26 junio: Socialización final

Momento	Tiempo	Actividad
Apertura	30 min	Pregunta problema y conexión con proyecto.
Explicación docente	60 min	Concepto central, error común y criterio técnico.
Demostración guiada	90 min	Presentar decisiones técnicas y entregables.
Trabajo del aprendiz	90 min	Aplicar el procedimiento en el dataset de trabajo.
Cierre y evidencia	30 min	Sustentación final.

11. Código base que debe orientar las prácticas

11.1 Carga y separación de variables

```
df = pd.read_csv('dataset_clientes_limpio_para_preprocesamiento.csv')
X = df.drop(columns=['Compra', 'ID_Cliente'])
y = df['Compra']
```

11.2 Codificación dummy con pandas

```
df_dummy = pd.get_dummies(df, columns=['Ciudad'], dtype=int)
```

11.3 Codificación ordinal

```
mapa = {'Bajo': 0, 'Medio': 1, 'Alto': 2}
df['NivelSatisfaccion_codificada'] = df['NivelSatisfaccion'].map(mapa)
```

11.4 Separación entrenamiento/prueba

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y
)
```

11.5 Preprocesador completo

```
preprocesador = ColumnTransformer(
    transformers=[
        ('num_std', StandardScaler(), ['Edad', 'CantidadCompras', 'AntiguedadMeses', 'DiasUltimaCompra']),
        ('num_robust', RobustScaler(), ['IngresoMensual', 'GastoPromedio']),
        ('ord', OrdinalEncoder(categories=[['Bajo', 'Medio', 'Alto']], ['NivelSatisfaccion']),
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), ['Ciudad', 'Genero', 'Segmento', 'CanalPreferido'])
    ],
    verbose_feature_names_out=False
)
```

12. Actividades de aprendizaje

Fase	Actividad	Producto
Reflexión	¿Está realmente listo mi dataset para IA?	Diagnóstico de variables y riesgos técnicos.
Contextualización	Del dato limpio al dato preparado	Mapa conceptual y discusión de errores comunes.
Apropiación	Codificación y escalamiento guiados	Ejercicios en notebook.
Transferencia	Construcción del dataset final	Notebook, train/test preparados e informe.
Evaluación	Socialización técnica	Exposición oral y entrega de evidencias.

13. Entregables obligatorios

No.	Entregable	Condición de aceptación
1	Notebook técnico	Debe estar ejecutado, comentado y organizado por secciones.
2	Dataset original limpio	Archivo base usado para la preparación.
3	Dataset train preparado	Archivo CSV transformado para entrenamiento.
4	Dataset test preparado	Archivo CSV transformado para prueba.
5	Diccionario de variables	Descripción, tipo y tratamiento aplicado.
6	Informe técnico	Documento con justificación de técnicas y conclusiones.
7	Socialización	Presentación breve del proceso y resultados.

14. Rúbrica de evaluación

Criterio	Peso	Nivel esperado
Diagnóstico de variables	10%	Clasifica variables y define tratamiento técnico.
Codificación categórica	20%	Aplica One-Hot y ordinal sin crear jerarquías falsas.
Escalamiento numérico	20%	Compara y selecciona escalador según características.
Train/test y fuga de información	15%	Separa antes de ajustar transformadores.
Pipeline reproducible	15%	Integra el flujo con ColumnTransformer y Pipeline.
Informe técnico	10%	Documenta con claridad y evidencias.
Socialización	10%	Sustenta decisiones y responde preguntas.

15. Niveles de desempeño

Nivel	Descripción
Bajo	Entrega incompleta, código no ejecutable o decisiones sin justificación.
Básico	Aplica técnicas, pero con errores menores o documentación limitada.
Alto	Aplica correctamente codificación, escalamiento y separación con buena documentación.
Superior	Integra pipeline reproducible, evita fuga de información, justifica cada decisión y sustenta con dominio técnico.

16. Lista de chequeo final del aprendiz

Criterio	Cumple	Observación
Identifiqué la variable objetivo		
Excluí ID o identificadores		
Clasifiqué variables nominales		
Clasifiqué variables ordinales		

Clasifiqué variables numéricas		
Apliqué One-Hot Encoding		
Apliqué codificación ordinal		
Seleccioné escaladores		
Separé train/test antes del fit		
Evité fuga de información		
Exporté datasets preparados		
Redacté informe técnico		
Preparé socialización		

17. Recomendaciones para el instructor

- No iniciar con código sin explicar primero el error técnico que se busca evitar.
- Solicitar siempre justificación de la técnica, no solo ejecución del código.
- Evaluar el proceso completo: diagnóstico, transformación, exportación y documentación.
- Usar el modelo de verificación solo para comprobar que el dataset fluye por un pipeline, no para centrar la clase en métricas de modelado.
- Pedir que los estudiantes comparen al menos dos escaladores antes de elegir uno.