

GUÍA 2 DE APRENDIZAJE

Selección de atributos, revisión de sesgo y balanceo de datasets para modelos de IA

1. Identificación general

Elemento	Descripción
Programa	Procesamiento de Datos para Modelos de Inteligencia Artificial
Guía	Guía 2 - Selección de atributos, sesgo y balanceo
Duración sugerida	60 horas
Distribución	12 sesiones de 5 horas
Modalidad	Presencial, virtual o combinada con práctica en laboratorio
Producto final	Dataset con atributos seleccionados, revisión de sesgo, conjunto de entrenamiento balanceado, conjunto de prueba conservado e informe técnico

2. Justificación

Esta guía continúa la ruta de preparación de datos para modelos de inteligencia artificial. Después de limpiar, transformar, codificar y escalar datos, el aprendiz debe verificar que el dataset no solo sea técnicamente procesable, sino también pertinente, representativo y útil para entrenamiento y evaluación. Por ello se trabaja la selección de atributos, la detección de redundancias, la revisión del desbalance de clases y la reducción de sesgo mediante técnicas de tratamiento de datos.

La guía se alinea con el propósito curricular de construir datasets de alta calidad y confiabilidad para modelos de IA, así como con el criterio de reducir el sesgo del dataset y segmentarlo para entrenamiento y prueba. También incorpora criterios de calidad del recurso didáctico digital: pertinencia pedagógica, claridad, secuencia, accesibilidad, evaluación, ética en IA y aplicabilidad en clase.

3. Competencias y resultados asociados

- Competencia: Sistematizar datos masivos de acuerdo con métodos de analítica y herramientas tecnológicas.
- Resultado: Preparar los datasets para entrenamiento y evaluación según el modelo de inteligencia artificial a emplear.
- Resultado: Documentar el proceso de acuerdo con procedimientos de la organización.
- Competencia relacionada: Integrar datos según técnicas de visualización y metodologías de análisis.

4. Problema formativo

Una organización cuenta con un dataset limpio, codificado y escalado. Sin embargo, aún no se ha verificado si todas las variables son pertinentes, si existen variables redundantes, si la variable objetivo está desbalanceada o si algún grupo del dataset está subrepresentado. Antes de entregar el dataset al equipo de modelado, se requiere seleccionar atributos relevantes, revisar sesgos potenciales, balancear el conjunto de entrenamiento y documentar las decisiones técnicas.

5. Pregunta orientadora

¿Cómo seleccionar atributos pertinentes y reducir riesgos de sesgo o desbalance para construir un dataset confiable antes del entrenamiento de un modelo de inteligencia artificial?

6. Objetivo general

Preparar un dataset optimizado para modelos de IA mediante selección de atributos, análisis de representatividad, revisión de desbalance de clases, balanceo del conjunto de entrenamiento y documentación técnica del proceso.

7. Objetivos específicos

- Identificar variables predictoras, objetivo, identificadoras y variables de revisión de representatividad.
- Evaluar la pertinencia de atributos usando criterio de negocio y criterio estadístico.
- Detectar variables redundantes o con baja variabilidad.
- Aplicar métodos de selección de atributos de filtro e integrados.
- Revisar la distribución de la variable objetivo y detectar desbalance de clases.
- Aplicar balanceo solo al conjunto de entrenamiento, evitando fuga de información.
- Construir datasets finales seleccionados y balanceados para entrenamiento y prueba.
- Elaborar informe técnico y socializar decisiones de preparación.

8. Saberes

Saber	Descripción
Saber conocer	Selección de atributos, variable objetivo, desbalance, sesgo, representatividad, redundancia, correlación, métodos de filtro, métodos integrados, fuga de información.
Saber hacer	Calcular distribución de clases, revisar grupos, aplicar selección de atributos, eliminar redundancias, balancear entrenamiento, exportar datasets y documentar decisiones.
Saber ser	Rigor, ética, transparencia, responsabilidad en el uso de datos, pensamiento crítico y capacidad de sustentar decisiones técnicas.

9. Cronograma por sesiones

Sesión	Tema	Producto de avance
Sesión 1	Reencuadre: del dataset preparado al dataset útil para IA	Diagnóstico del dataset y revisión de la Guía 1.
Sesión 2	Variable objetivo y distribución de clases	Cálculo de proporciones y detección de desbalance.
Sesión 3	Representatividad y revisión de sesgo	Análisis por grupos: zona, ciudad, segmento y satisfacción.
Sesión 4	Selección de atributos con criterio de negocio	Matriz: variable, utilidad, riesgo, decisión.
Sesión 5	Métodos de filtro	Varianza, correlación, ANOVA/F-score y ranking inicial.
Sesión 6	Métodos integrados	Importancia de atributos con modelo de árboles como apoyo técnico.
Sesión 7	Redundancia y multicolinealidad	Identificación de variables duplicadas o altamente correlacionadas.
Sesión 8	Balanceo de clases	Submuestreo, sobremuestreo y precauciones metodológicas.
Sesión 9	Entrenamiento/prueba sin fuga de información	Balanceo solo en entrenamiento y conservación del conjunto de prueba.
Sesión 10	Construcción del dataset final	Exportación de datasets seleccionados y balanceados.
Sesión 11	Informe técnico y lista de chequeo	Redacción de informe, evidencias y validación final.
Sesión 12	Socialización técnica	Sustentación de decisiones y retroalimentación.

10. Producto final

- Notebook técnico con diagnóstico, selección de atributos, revisión de sesgo, balanceo y exportación.
- Dataset de entrenamiento seleccionado y balanceado.
- Dataset de prueba seleccionado y sin balancear artificialmente.

- Ranking de atributos por método de filtro e importancia de modelo.
- Informe técnico del proceso.
- Socialización final con decisiones técnicas y evidencias.

11. Evidencias de aprendizaje

Tipo	Evidencia
Conocimiento	Cuestionario o sustentación sobre selección de atributos, sesgo, desbalance y fuga de información.
Desempeño	Notebook con análisis y aplicación de técnicas sobre el dataset.
Producto	Dataset final seleccionado y balanceado, informe técnico y socialización.

12. Rúbrica resumida

Criterio	Básico	Alto	Superior
Selección de atributos	Selecciona variables sin justificar completamente.	Justifica variables con criterio técnico.	Integra criterio técnico, estadístico y de negocio.
Revisión de sesgo	Reconoce grupos del dataset.	Calcula distribución por grupos.	Interpreta riesgos y propone acciones responsables.
Balanceo	Identifica desbalance.	Aplica balanceo en entrenamiento.	Evita fuga, compara antes/después y documenta impacto.
Documentación	Describe parcialmente el proceso.	Documenta decisiones y resultados.	Presenta informe claro, trazable y sustentado.

13. Orientaciones éticas y de uso de IA

- El aprendiz puede usar IA para explicar conceptos, depurar errores o mejorar redacción, pero debe declarar su uso en el informe.
- No debe usar IA para inventar resultados ni modificar evidencias del dataset.
- Toda decisión técnica debe estar justificada con datos, código y resultados reproducibles.
- La revisión de sesgo debe tratarse como una responsabilidad técnica y ética, no como un requisito decorativo.