

GUÍA 2 - MATERIAL EXPLICATIVO ASOCIADO AL NOTEBOOK

Selección de atributos, revisión de sesgo, varianza y balanceo de datasets para modelos de IA

Propósito del documento

Este PDF explica paso a paso qué se hace en el notebook de la Guía 2, por qué se hace, cómo interpretar los resultados y qué impacto tiene cada decisión en el procesamiento de datos para modelos de inteligencia artificial.

Elemento	Descripción
Guía asociada	Guía 2: Selección de atributos, revisión de sesgo y balanceo de datasets para modelos de IA
Producto que acompaña	Notebook resuelto y explicado de la Guía 2
Dataset de trabajo	Clientes con variable objetivo Abandono
Pregunta central	¿El dataset tiene variables útiles, representación adecuada y clases suficientemente balanceadas para modelar?
Enfoque	Diagnóstico técnico antes del modelamiento, no entrenamiento final de un modelo.

1. ¿Qué busca la Guía 2?

La Guía 2 busca que el aprendiz no use el dataset de forma automática. Aunque el dataset ya venga limpio, codificado o escalado, todavía debe revisarse si sus variables aportan información, si existen riesgos de sesgo o representatividad y si la variable objetivo está desbalanceada.

Idea clave

No basta con que un dataset esté limpio. También debe ser pertinente, representativo, explicable y técnicamente adecuado para el modelo que se desea construir.

Pregunta de la guía	Cómo se responde en el notebook	Evidencia esperada
¿Qué variables aportan al modelo?	Con revisión de tipos, varianza, redundancia, F-score e importancia de variables.	Ranking de atributos y tabla de variables seleccionadas.
¿El dataset tiene posibles sesgos?	Con análisis de distribución por grupos y tasas de abandono por categoría.	Tablas por zona, ciudad, canal, segmento y satisfacción.
¿La variable objetivo está balanceada?	Con conteos, porcentajes y relación entre clase mayoritaria y minoritaria.	Diagnóstico de desbalance y dataset de entrenamiento balanceado.

2. Mapa general del notebook

El notebook está organizado en 17 bloques. Cada bloque cumple una función dentro del procesamiento de datos previo al modelamiento.

Bloque	Tema	Función principal
1	Importar librerías	Cargar herramientas para manipulación, preprocesamiento, selección, balanceo y métricas.
2	Cargar dataset	Leer el archivo base y verificar que los datos estén disponibles.
3	Diagnóstico inicial	Revisar filas, columnas y tipos de datos.
4	Variable objetivo y desbalance	Identificar la variable Abandono y medir la distribución de clases.
5	Clasificación técnica de variables	Separar identificadoras, numéricas, nominales, ordinales y objetivo.
6	Representatividad y sesgo	Analizar si algunos grupos están sobrerrepresentados o tienen tasas distintas de abandono.
7	Entrenamiento/prueba	Separar datos conservando la proporción de clases.
8	Preprocesamiento	Escalar y codificar sin fuga de información.
9	Varianza	Detectar variables con baja variabilidad.
10	Redundancia	Detectar variables que repiten información.
11	F-score	Medir relación estadística individual con la variable objetivo.
12	Random Forest	Estimar importancia de variables usando un modelo básico.
13	Selección final	Combinar evidencia técnica y criterio de negocio.
14	Datasets seleccionados	Construir train/test con atributos seleccionados.
15	Balanceo	Balancear solo el conjunto de entrenamiento.
16	Verificación rápida	Comparar modelo sin balanceo y modelo con entrenamiento balanceado.
17	Exportación	Guardar rankings, datasets y métricas.

3. Bloque 1: Importar librerías

El notebook inicia importando librerías. Esto prepara el ambiente de trabajo para manipular datos, preprocesar variables, seleccionar atributos, balancear clases y calcular métricas.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
```

```

from sklearn.preprocessing import OneHotEncoder, OrdinalEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.feature_selection import VarianceThreshold, SelectKBest, f_classif
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score, f1_score, recall_score, precision_score
from sklearn.utils import resample

```

Librería / función	Uso en la guía
pandas / numpy	Manipulación y análisis del dataset.
train_test_split	Separación entre entrenamiento y prueba.
OneHotEncoder	Codificación de variables nominales.
OrdinalEncoder	Codificación de variables ordinales como Segmento y Satisfacción.
StandardScaler	Escalamiento de variables numéricas.
VarianceThreshold	Revisión de variables con baja variabilidad.
SelectKBest / f_classif	Ranking estadístico de atributos.
RandomForestClassifier	Modelo básico para estimar importancia de variables.
resample	Sobremuestreo para balancear la clase minoritaria en entrenamiento.

4. Bloques 2 y 3: Cargar y diagnosticar el dataset

Antes de seleccionar atributos o revisar sesgo, se debe confirmar que el dataset cargó correctamente y conocer su estructura. El notebook usa head(), shape, dtypes e info() para revisar las primeras filas, dimensiones y tipos de datos.

Resultado del diagnóstico	Interpretación
360 filas	Hay 360 registros de clientes. Cada fila representa un cliente.
18 columnas	El dataset contiene identificador, variables numéricas, variables categóricas y la variable objetivo.
Tipos int64, float64 y object	Existen variables numéricas y variables de texto que requieren tratamiento.
Sin nulos en las columnas reportadas	El dataset está listo para análisis de selección, representatividad y balanceo.
Por qué importa Si el aprendiz no revisa la estructura del dataset, puede usar mal una variable: por ejemplo, tratar una variable ordinal como nominal, incluir un identificador como predictor o usar la variable objetivo como entrada.	

5. Bloque 4: Variable objetivo y diagnóstico de desbalance

La variable objetivo es Abandono. Esta columna indica si el cliente abandonó o no. En problemas supervisados, la variable objetivo es la respuesta que el modelo intentará aprender a predecir.

```

objetivo = 'Abandono'
df[objetivo].value_counts()
df[objetivo].value_counts(normalize=True).round(4)

```

Clase	Significado	Cantidad	Porcentaje
0	Cliente no abandonó	268	74.44%
1	Cliente sí abandonó	92	25.56%

La relación entre clase mayoritaria y minoritaria es aproximadamente 2.91 a 1. Esto significa que por cada cliente que abandonó hay casi tres clientes que no abandonaron.

¿Se solucionó el desbalance aquí?

No. Este bloque solo diagnostica el desbalance. Contar las clases no cambia el dataset. El tratamiento del desbalance se realiza más adelante y únicamente sobre el conjunto de entrenamiento.

6. Bloque 5: Clasificación técnica de variables

El notebook clasifica las variables para decidir qué tratamiento debe recibir cada una. Esta clasificación evita errores técnicos durante el procesamiento.

Grupo	Variables	Tratamiento
Identificadora	ID_Cliente	No se usa como predictor. Solo sirve para trazabilidad.
Númericas	Edad, IngresoMensual, CantidadCompras, ComprasUltimos12M, AntigüedadMeses, QuejasUltimos6M, DiasDesdeUltimaCompra, VisitasWebUltimoMes, TiempoPromedioSesionMin, CuponesUsados	Se evalúan como atributos candidatos y pueden escalarse.
Catógoricas nominales	Ciudad, CanalPreferido, ZonaResidencia, CodigoCampania	No tienen orden natural. Si se usan, se codifican con One-Hot Encoding.
Catógoricas ordinales	Segmento, Satisfaccion	Tienen orden lógico. Se codifican con OrdinalEncoder.
Objetivo	Abandono	No se usa como predictor porque es la respuesta que se quiere predecir.
Control de errata Segmento debe tratarse como ordinal, no como nominal. El orden correcto es Básico < Medio < Premium. Satisfaccion también es ordinal: Baja < Media < Alta.		

7. Bloque 6: Representatividad y posible sesgo

La revisión de representatividad permite observar si algunos grupos aparecen mucho más que otros o si presentan tasas de abandono diferentes. Esto no prueba por sí solo discriminación, pero sí alerta sobre posibles riesgos de sesgo o baja representación.

Variable revisada	Hallazgo	Impacto
ZonaResidencia	Urbana representa 66.11%; rural y periurbana 16.94% cada una.	El modelo puede aprender más patrones urbanos que rurales o periurbanos.
Segmento	Básico representa cerca de 49.44%; Premium cerca de 19.44%.	El comportamiento de Premium puede quedar menos representado.
Satisfaccion	La satisfacción baja es menos frecuente, pero puede tener mayor tasa de abandono.	Aunque sea menos frecuente, puede ser muy informativa.
Ciudad y CanalPreferido	Permiten analizar diferencias territoriales y de interacción.	Deben revisarse antes de usarlas como predictoras.
Idea para el aprendiz Una variable puede ser útil para auditoría aunque no se use como predictor. Por ejemplo, ZonaResidencia ayuda a revisar representatividad y posibles diferencias entre grupos.		

8. Bloque 7: Separación entrenamiento/prueba estratificada

El notebook separa los datos en entrenamiento y prueba. La separación es estratificada, es decir, conserva aproximadamente la misma proporción de clases en ambos conjuntos.

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y
)
```

Conjunto	Clase 0	Clase 1	Porcentaje clase 0	Porcentaje clase 1
Entrenamiento	201	69	74.44%	25.56%
Prueba	67	23	74.44%	25.56%
Por qué se usa stratify Si no se usa estratificación, una separación aleatoria podría dejar muy pocos casos de abandono en entrenamiento o prueba. Eso afectaría el aprendizaje y la evaluación.				

9. Bloque 8: Preprocesamiento sin fuga de información

El preprocesamiento convierte el dataset en una matriz lista para análisis de atributos. Se escalan variables numéricas, se codifican variables nominales y se codifican variables ordinales.

Tipo de variable	Transformación	Razón
Númerica	StandardScaler	Llevar variables a una escala comparable.
Nominal	OneHotEncoder	Crear columnas binarias sin imponer orden falso.
Ordinal	OrdinalEncoder	Conservar el orden lógico de categorías.
Regla técnica importante El preprocesador se ajusta con fit_transform sobre X_train y se aplica con transform sobre X_test. No se debe ajustar con datos de prueba porque eso genera fuga de información.		

Resultado	Interpretación
X_train_df: (270, 30)	Después de codificar y escalar, el entrenamiento queda con 270 registros y 30 atributos.
X_test_df: (90, 30)	La prueba queda con 90 registros y las mismas 30 columnas.

10. Bloque 9: Varianza y baja variabilidad

La varianza mide cuánto cambian los valores de una variable respecto a su promedio. En procesamiento de datos, se usa para detectar columnas que no cambian o cambian muy poco.

Definición sencilla

Una variable con alta variabilidad diferencia mejor los registros. Una variable con varianza cero tiene siempre el mismo valor y no aporta información para distinguir casos.

Ejemplo	Valores	Interpretación
Variable constante	Colombia, Colombia, Colombia, Colombia	No aporta información porque todos los registros son iguales.
Baja variabilidad	0, 0, 0, 0, 1	Puede aportar poca información, pero debe revisarse antes de eliminar.
Variabilidad útil	18, 25, 40, 55, 70	Permite diferenciar registros.
Varianza alta	1200, 1500, 1800, 90000	Puede indicar escala amplia o posible valor extremo.

En el notebook se usa VarianceThreshold para detectar variables con baja variabilidad después del preprocesamiento.

```
selector_varianza = VarianceThreshold(threshold=0.01)
selector_varianza.fit(X_train_df)
variables_baja_varianza = X_train_df.columns[~selector_varianza.get_support()]
```

Resultado del notebook	Interpretación
Variables con baja variabilidad detectadas: 0	No se encontraron atributos con variabilidad tan baja como para eliminarlos por este criterio.
No se elimina ninguna variable por varianza	La varianza se usó como filtro diagnóstico, no como decisión automática.

10.1 Función de la varianza en la Guía 2

Función	Impacto en el procesamiento
Detectar variables constantes	Evita usar columnas que no diferencian clientes.
Detectar baja variabilidad	Permite revisar variables que casi siempre tienen el mismo valor.
Advertir posibles outliers	Una varianza muy alta puede sugerir valores extremos o escalas desproporcionadas.
Apoyar selección de atributos	Reduce ruido antes del modelamiento.
Justificar escalamiento	Variables con escalas muy distintas pueden requerir transformación previa.

Cuidado didáctico

La varianza ayuda a decidir, pero no decide sola. Una variable con baja varianza podría ser útil si esos pocos casos distintos están muy relacionados con la variable objetivo.

11. Bloque 10: Redundancia entre variables numéricas

La redundancia ocurre cuando dos variables contienen información muy parecida. Si dos columnas están muy correlacionadas, conservar ambas puede agregar complejidad sin aportar nueva información.

Resultado detectado	Interpretación	Decisión
CantidadCompras y ComprasUltimos12M tienen correlación 0.932	La relación es muy alta; ambas variables miden comportamiento de compra.	Evitar conservar ambas si se busca un conjunto de atributos más simple.
Impacto de la redundancia Reducir variables redundantes puede mejorar la claridad del dataset, disminuir ruido y facilitar la explicación del modelo.		

12. Bloque 11: Selección por F-score

El F-score es un método de filtro. Evalúa cada atributo de forma individual y estima qué tanto ayuda a diferenciar las clases de la variable objetivo. No entrena un modelo final; solo genera un ranking estadístico.

Top atributo según F-score	Puntaje aproximado	Interpretación
Satisfaccion	23.12	Muy relacionada con el abandono.
QuejasUltimos6M	19.81	Las quejas recientes son relevantes.
Segmento	13.06	El nivel comercial puede estar asociado al abandono.
CuponesUsados	5.14	Puede aportar información sobre comportamiento promocional.
ZonaResidencia_Urbana	4.91	Puede marcar diferencias por residencia.
Limitación del F-score El F-score analiza variables de forma individual. Puede no detectar relaciones combinadas entre variables. Por eso se complementa con un modelo como Random Forest.		

13. Bloque 12: Importancia de variables con Random Forest

Random Forest se usa como método integrado para estimar importancia de variables. A diferencia del F-score, analiza variables dentro de un modelo y puede capturar relaciones más complejas.

Top atributo según Random Forest	Importancia aproximada	Interpretación
Satisfaccion	0.101	Aparece como variable más importante.
Edad	0.088	Aporta información demográfica.
IngresoMensual	0.086	Puede aportar información económica.
AntigüedadMeses	0.079	Tiempo de relación con la empresa.
QuejasUltimos6M	0.074	Se mantiene como variable relevante.

14. Bloque 13: Selección final de atributos

La selección final combina evidencia estadística, importancia de modelo, sentido de negocio, revisión de baja variabilidad y revisión de redundancia.

Atributos seleccionados en el notebook
Satisfaccion, QuejasUltimos6M, Segmento, CuponesUsados, ZonaResidencia_Urbana, Edad, DiasDesdeUltimaCompra, ZonaResidencia_Rural, CantidadCompras, IngresoMensual, AntigüedadMeses, TiempoPromedioSesionMin
Decisión importante Si CantidadCompras y ComprasUltimos12M aparecen juntas, se elimina ComprasUltimos12M para controlar redundancia. Esta decisión no es matemática únicamente; también debe justificarse desde el negocio.

15. Bloque 14: Construcción de datasets seleccionados

Después de seleccionar atributos, el notebook crea dos nuevos datasets: uno para entrenamiento y otro para prueba. Ambos incluyen solo los atributos seleccionados y la variable objetivo.

Dataset	Dimensión	Uso
train_selected	270 filas x 13 columnas	Entrenamiento sin balancear con atributos seleccionados + objetivo.
test_selected	90 filas x 13 columnas	Evaluación con datos no vistos. No se balancea.

16. Bloque 15: Balanceo solo del conjunto de entrenamiento

El balanceo se aplica para que el modelo tenga más oportunidad de aprender la clase minoritaria. En esta guía se usa sobremuestreo de la clase 1 dentro del conjunto de entrenamiento.

Momento	Clase 0	Clase 1	Conclusión
Antes de balancear entrenamiento	201	69	Se mantiene el desbalance original.
Después de balancear entrenamiento	201	201	El entrenamiento queda balanceado 50%-50%.
Respuesta clara Sí se solucionó el desbalance, pero solo en el conjunto de entrenamiento balanceado. No se modifica el dataset original ni el conjunto de prueba.			

Por qué no se balancea la prueba

La prueba debe representar una situación realista. Si se balancea artificialmente, las métricas ya no reflejan el desempeño del modelo sobre datos parecidos a los reales.

17. Bloque 16: Verificación rápida con modelo básico

El modelo básico no se usa como producto final, sino como una prueba de impacto: se compara un modelo entrenado sin balanceo contra otro entrenado con el conjunto balanceado.

Escenario	Accuracy	Balanced Accuracy	F1 clase 1	Recall clase 1	Precision clase 1
Sin balanceo	0.789	0.601	0.345	0.217	0.833
Con entrenamiento balanceado	0.722	0.685	0.528	0.609	0.467

Aunque el modelo sin balanceo tiene mayor accuracy, detecta pocos clientes que abandonan. El modelo balanceado reduce accuracy, pero mejora balanced accuracy, F1 y recall de la clase 1.

Matriz	Predicho 0 cuando real 0	Predicho 1 cuando real 0	Predicho 0 cuando real 1	Predicho 1 cuando real 1
Sin balanceo	66	1	18	5
Con balanceo	51	16	9	14

Interpretación de negocio En abandono de clientes suele importar detectar la clase 1. El modelo balanceado identifica 14 de 23 abandonos, mientras el modelo sin balanceo identifica solo 5 de 23. Por eso el recall de clase 1 mejora.				
---	--	--	--	--

18. Cómo interpretar las métricas usadas

Métrica	Qué mide	Cómo interpretarla en abandono
Accuracy	Proporción total de aciertos.	Puede ser engañosa si la clase 0 domina.
Balanced Accuracy	Promedio del desempeño por clase.	Más útil cuando hay desbalance.
Recall clase 1	De los clientes que abandonaron, cuántos detectó el modelo.	Muy importante si se quiere anticipar abandono.
Precision clase 1	De los clientes predichos como abandono, cuántos realmente abandonaron.	Importante para no generar demasiadas falsas alertas.
F1 clase 1	Equilibrio entre precision y recall.	Útil cuando interesa balancear detección y confiabilidad.

19. Bloque 17: Exportación de entregables

El notebook guarda los productos de la Guía 2 para que el aprendiz pueda entregar evidencia del proceso.

Archivo generado	Contenido
ranking_ atributos_ fscore_ guia2.csv	Ranking de atributos según F-score.
ranking_ atributos_ random_ forest_ guia2.csv	Ranking de importancia según Random Forest.
atributos_ seleccionados_ guia2.csv	Lista final de atributos seleccionados.
dataset_ train_ seleccionado_ sin_ balancear_ guia2.csv	Entrenamiento seleccionado antes del balanceo.
dataset_ train_ seleccionado_ balanceado_ guia2.csv	Entrenamiento seleccionado y balanceado.
dataset_ test_ seleccionado_ guia2.csv	Prueba seleccionada sin balancear.
metricas_ verificacion_ balanceo_ guia2.csv	Comparación de métricas sin balanceo vs con balanceo.

20. Conclusión integrada para el aprendiz

- La variable objetivo Abandono presenta un desbalance moderado: 74.44% clase 0 y 25.56% clase 1.
- El conteo de clases solo diagnostica el desbalance; no lo corrige.
- La varianza se usa para detectar variables que no cambian o cambian muy poco; en este caso no se detectaron variables de baja variabilidad.
- La redundancia permitió identificar alta correlación entre CantidadCompras y ComprasUltimos12M.
- F-score y Random Forest ayudan a priorizar variables, pero no reemplazan el criterio técnico ni de negocio.
- El balanceo se aplicó correctamente solo al conjunto de entrenamiento.
- El conjunto de prueba se mantuvo intacto para evaluar con una distribución realista.
- El modelo balanceado mejoró la detección de abandonos, aunque bajó el accuracy general.

Frase final para clase

En la Guía 2 no buscamos entrenar el mejor modelo. Buscamos demostrar que el dataset fue revisado, que sus variables fueron seleccionadas con criterio, que sus riesgos de sesgo fueron analizados y que el desbalance fue tratado correctamente antes de avanzar al modelamiento.

21. Plantilla de redacción para el informe del aprendiz

El aprendiz puede usar la siguiente estructura para redactar su análisis:

Modelo de conclusión

Se identificó que la variable objetivo Abandono presenta un desbalance moderado, dado que la clase 0 representa el 74.44% y la clase 1 el 25.56%. Esta situación puede generar un sesgo del modelo hacia la clase mayoritaria. Por esta razón, se aplicó balanceo únicamente sobre el conjunto de entrenamiento. Además, se revisaron variables candidatas mediante análisis de varianza, redundancia, F-score e importancia de variables con Random Forest. Como resultado, se obtuvo un conjunto de atributos seleccionados, un dataset de entrenamiento balanceado y un conjunto de prueba sin alterar para una evaluación más realista.