

Manual teórico-práctico del aprendiz

Guía 3 V3 - Aprendizaje supervisado para clasificación binaria

Elemento	Descripción
Programa	Procesamiento de Datos para Modelos de Inteligencia Artificial
Tema	Preparación para aprendizaje supervisado
Caso	Predicción de abandono de clientes
Propósito	Comprender, entrenar, evaluar e interpretar modelos supervisados básicos
Versión	V3 pedagógica ampliada

Presentación del manual

Este manual fue diseñado para que el aprendiz no llegue al notebook sin comprender el sentido de la práctica. Antes de entrenar modelos, es necesario entender qué problema se está resolviendo, qué significa aprender con datos, qué representa la variable objetivo, por qué se separan datos de entrenamiento y prueba, cómo se interpretan los errores y por qué un número alto en una métrica no siempre significa que el modelo sea útil o responsable.

La guía trabaja un caso de abandono de clientes. En este contexto, una empresa quiere anticipar qué clientes podrían dejar de comprar o cancelar su relación comercial. El modelo no reemplaza la decisión humana; ayuda a priorizar análisis, seguimiento y acciones preventivas. Por eso, el aprendiz debe aprender a leer resultados con criterio y comunicar límites.

1. De preparar datos a modelar: ¿qué cambia en la Guía 3?

En las guías anteriores se trabajaron procesos necesarios para que los datos pudieran ser utilizados por herramientas de análisis e inteligencia artificial: limpieza, transformación, codificación de variables categóricas, escalamiento de variables numéricas, selección de atributos, revisión de sesgo y balanceo. Todo eso responde a una condición previa: un modelo solo puede aprender bien si los datos están organizados, son coherentes y representan adecuadamente el problema.

En la Guía 3 aparece un nuevo paso: usar esos datos para entrenar modelos supervisados. Esto implica pasar de la preparación del dataset a la evaluación del comportamiento de un algoritmo. Ya no solo preguntamos si las columnas están limpias o codificadas, sino si el modelo puede aprender una relación entre las características de los clientes y la variable Abandono.

Guía	Pregunta central
Guía 0	¿Los datos están limpios y transformados?
Guía 1	¿Los datos están codificados, escalados y listos técnicamente?
Guía 2	¿Las variables son pertinentes, representativas y balanceadas?
Guía 3	¿Un modelo supervisado puede aprender e interpretar abandono?

2. ¿Qué es inteligencia artificial en este contexto?

En este programa, la inteligencia artificial se aborda desde una perspectiva práctica: utilizar datos para apoyar análisis, predicciones y decisiones. No se trata de que la máquina piense como una persona, sino de usar algoritmos capaces de encontrar patrones en registros históricos. Si muchos clientes con baja satisfacción y muchas quejas abandonan, un algoritmo puede identificar esa relación y usarla para clasificar nuevos clientes.

La inteligencia artificial aplicada a datos requiere una cadena completa: identificar el problema, recolectar información, limpiar datos, preparar variables, revisar sesgos, entrenar modelos, evaluar resultados, documentar hallazgos y mantener revisión humana. La Guía 3 se ubica específicamente en la etapa de entrenamiento y evaluación inicial de modelos supervisados.

3. ¿Qué es aprendizaje automático?

El aprendizaje automático o machine learning es una técnica que permite que un algoritmo encuentre patrones a partir de datos. En lugar de escribir manualmente todas las reglas, el equipo entrega ejemplos históricos y el algoritmo calcula relaciones entre variables. Por ejemplo, en vez de programar una regla rígida como “si el cliente no compra en 90 días, entonces abandona”, el modelo revisa múltiples variables al mismo tiempo: compras, quejas, visitas web, satisfacción, segmento y tiempo desde la última compra.

Esto no significa que el modelo comprenda al cliente como una persona. El modelo trabaja con relaciones matemáticas. Por eso, el aprendiz debe entender que entrenar un modelo no es sinónimo de obtener verdad absoluta. El modelo produce una aproximación basada en los datos que recibió.

4. Tipos generales de aprendizaje automático

Tipo	Descripción	Ejemplo
Supervisado	Aprende con ejemplos que tienen respuesta conocida.	Predecir abandono: 0 o 1.
No supervisado	Busca patrones sin una respuesta previamente marcada.	Agrupar clientes similares.
Por refuerzo	Aprende por interacción, recompensa o penalización.	Sistemas que optimizan acciones mediante ensayo y error.

La Guía 3 trabaja aprendizaje supervisado porque el dataset contiene una respuesta conocida: la columna Abandono. El modelo observará registros históricos donde ya se sabe si el cliente abandonó o no, y luego intentará clasificar nuevos casos.

5. ¿Qué es aprendizaje supervisado?

El aprendizaje supervisado es como estudiar con ejemplos resueltos. Cada fila del dataset tiene características del cliente y una respuesta conocida. El modelo observa esos ejemplos y ajusta sus reglas internas para relacionar las características con la respuesta. Luego, cuando recibe un cliente nuevo sin respuesta conocida, intenta predecir la clase correcta.

Variable 1	Variable 2	Variable 3	Variable 4	Respuesta conocida
Edad	IngresoMensual	QuejasUltimos6M	Satisfaccion	Abandono
32	2500	0	Alta	0
58	1200	3	Baja	1
41	3100	1	Media	0

En la tabla anterior, Abandono es la respuesta conocida. Las demás columnas son posibles señales que el modelo puede usar para aprender. Si se entrega Abandono como entrada, el modelo haría trampa porque estaría recibiendo la respuesta que debe predecir.

6. Clasificación y regresión

Dentro del aprendizaje supervisado existen dos tareas comunes: clasificación y regresión. La clasificación predice categorías. La regresión predice valores numéricos continuos. Nuestro caso es clasificación porque Abandono tiene dos clases posibles: 0 y 1.

Tarea	Qué predice	Ejemplos
Clasificación	Categoría	Abandona/no abandona, fraude/no fraude, aprobado/no aprobado
Regresión	Número continuo	Valor de venta, ingreso esperado, demanda futura

7. ¿Qué es clasificación binaria?

La clasificación binaria es una clasificación con solo dos posibles respuestas. En el caso de abandono, normalmente se codifica como 0 y 1. La clase 0 representa “no abandona” y la clase 1 representa “sí abandona”. La clase 1 suele llamarse clase positiva porque representa el evento que se desea detectar.

Valor	Interpretación	Rol
0	Cliente no abandonó	Clase negativa
1	Cliente sí abandonó	Clase positiva

Esta distinción es muy importante porque muchas métricas se interpretan desde la clase positiva. En abandono de clientes, lo más importante puede ser detectar clientes que sí abandonan, no simplemente acertar muchos casos de clientes que no abandonan.

8. Variable objetivo y variables predictoras

La variable objetivo es la columna que se quiere predecir. En esta guía es Abandono. Las variables predictoras son las columnas que el modelo usa como entrada para intentar predecir esa respuesta. En Python y en ciencia de datos, se suele llamar X al conjunto de variables predictoras y y a la variable objetivo.

Símbolo/decisión	Significado	Ejemplo
X	Variables predictoras	Edad, compras, quejas, satisfacción, segmento, canal, ciudad
y	Variable objetivo	Abandono
No usar como X	Identificadores o respuesta	ID_Cliente, Abandono

Actividad 1: Identificar X e y

- Marque en el diccionario cuál es la variable objetivo.
- Liste cinco variables predictoras posibles.
- Explique por qué ID_Cliente no debe usarse para entrenar.
- Explique qué pasaría si Abandono se incluye dentro de X.

9. ¿Qué significa entrenar un modelo?

Entrenar un modelo significa permitir que el algoritmo use datos históricos para ajustar sus parámetros internos. Durante el entrenamiento, el modelo compara sus predicciones con la respuesta real y modifica su comportamiento para equivocarse menos. Dependiendo del algoritmo, este ajuste puede hacerse de distintas formas.

Una analogía útil es la siguiente: un aprendiz estudia resolviendo ejercicios que ya tienen respuesta. Con el tiempo reconoce patrones. Luego, en un examen, enfrenta ejercicios nuevos. Si solo memorizó los ejercicios, puede fallar. Si aprendió el patrón, puede resolver casos nuevos. Lo mismo ocurre con un modelo.

10. ¿Qué significa evaluar un modelo?

Evaluar un modelo significa medir cómo se comporta ante datos que no usó para aprender. Este paso es fundamental. Si evaluamos con los mismos datos usados para entrenar, el resultado puede ser demasiado optimista. El modelo puede haber memorizado los datos de entrenamiento y fallar con casos nuevos.

Conjunto	Función
Entrenamiento	Datos usados para aprender patrones.
Prueba	Datos reservados para evaluar con casos no vistos.
Validación	Opcionalmente, datos o proceso usado para ajustar decisiones durante desarrollo.

11. División entrenamiento/prueba

En esta guía se divide el dataset en entrenamiento y prueba. Una división frecuente es 80% para entrenamiento y 20% para prueba. También se utiliza stratify=y para conservar proporciones similares de las clases 0 y 1 en ambos conjuntos. Esto ayuda a que entrenamiento y prueba representen de forma parecida la distribución de la variable objetivo.

Ejemplo conceptual

Parte	Cantidad aproximada	Uso
Dataset completo	360 clientes	100%
Entrenamiento	288 clientes	80%
Prueba	72 clientes	20%

12. Fuga de información

La fuga de información es uno de los errores más graves en modelamiento. Ocurre cuando el modelo recibe directa o indirectamente información que no debería conocer en una situación real. Esto puede producir métricas altas pero falsas. Un modelo con fuga de información no es confiable.

Error	Por qué es fuga
Incluir Abandono dentro de X	El modelo recibe la respuesta.
Escalar antes de dividir train/test	El conjunto de prueba influye en el escalador.
Codificar usando todo el dataset antes de separar	La prueba deja de ser completamente independiente.
Elegir modelo mirando repetidamente el test	El conjunto de prueba se contamina como herramienta de ajuste.

13. Pipeline y ColumnTransformer

Un pipeline es una forma ordenada de encadenar pasos. En esta guía se utiliza para unir preprocesamiento y modelo. El ColumnTransformer permite aplicar tratamientos diferentes a columnas numéricas, ordinales y nominales. Esto es clave porque no todas las variables se preparan igual.

Tipo de columna	Tratamiento	Ejemplo
Numéricas	StandardScaler	Edad, IngresoMensual, compras, quejas
Ordinales	OrdinalEncoder	Segmento: Básico < Medio < Premium; Satisfaccion: Baja < Media < Alta
Nominales	OneHotEncoder	Ciudad, CanalPreferido, ZonaResidencia, CódigoCampania

14. Control de la errata: Segmento no es nominal

En la ruta de aprendizaje se detectó una errata importante: Segmento no debe tratarse como variable nominal si sus valores representan un nivel comercial. Básico, Medio y Premium tienen una jerarquía lógica. Por tanto, Segmento debe tratarse como variable categórica ordinal. Lo mismo ocurre con Satisfaccion: Baja, Media y Alta tienen orden natural.

Variable	Orden	Tratamiento
Segmento	Básico < Medio < Premium	Ordinal
Satisfaccion	Baja < Media < Alta	Ordinal
Ciudad	Sin orden natural	Nominal

15. Modelos básicos que se pueden comparar

En una primera práctica no se requiere usar modelos avanzados. Lo importante es comparar alternativas sencillas bajo las mismas condiciones. En esta guía se pueden usar regresión logística, árbol de decisión y bosque aleatorio básico. Cada uno tiene ventajas y limitaciones.

Modelo	Ventaja	Cuidado
Regresión logística	Modelo lineal para clasificación. Puede ser buen modelo base.	Es sensible al preprocesamiento y puede no capturar relaciones complejas.
Árbol de decisión	Fácil de interpretar y maneja reglas.	Puede sobreajustarse si no se limita su profundidad.
Bosque aleatorio	Combina muchos árboles y suele ser más robusto.	Es menos interpretable que un árbol simple.

16. ¿Qué es predecir?

Después de entrenar, el modelo puede recibir registros nuevos y producir una clase estimada. En clasificación binaria, la predicción puede ser 0 o 1. Algunos modelos también producen probabilidades. Por ejemplo, un cliente podría tener probabilidad 0.72 de abandono. La decisión de actuar sobre esa probabilidad depende del negocio y debe ser revisada por una persona.

17. Matriz de confusión explicada

La matriz de confusión organiza los aciertos y errores del modelo. Es una herramienta fundamental porque permite ver qué tipo de errores comete. En abandono de clientes, no todos los errores tienen el mismo costo.

Celda	Significado	Interpretación de negocio
Verdadero negativo (TN)	El cliente no abandonó y el modelo predijo que no abandonaría.	Acuerdo correcto de clase 0.
Falso positivo (FP)	El cliente no abandonó, pero el modelo predijo abandono.	Falsa alarma; puede generar intervención innecesaria.
Falso negativo (FN)	El cliente abandonó, pero el modelo no lo detectó.	Error crítico: se escapó un cliente en riesgo.
Verdadero positivo (TP)	El cliente abandonó y el modelo lo detectó.	Acuerdo importante de clase 1.

18. Accuracy

Accuracy mide cuántas predicciones fueron correctas sobre el total de casos. Es fácil de entender, pero no siempre es suficiente. Si el dataset está desbalanceado, accuracy puede ser alto aunque el modelo falle en la clase que más interesa.

Ejemplo numérico

Elemento	Lectura
100 clientes	80 no abandonan y 20 abandonan
Modelo ingenuo	Predice que nadie abandona
Accuracy	80% de aciertos
Problema	No detectó ningún abandono real

19. Precision

Precision responde esta pregunta: de todos los clientes que el modelo marcó como abandono, ¿cuántos realmente abandonaron? Es importante cuando una intervención tiene costo y se quieren evitar falsas alarmas.

Situación	Interpretación
Alta precision	La mayoría de alertas de abandono son correctas.
Baja precision	Muchas alertas son falsas alarmas.

20. Recall

Recall responde esta pregunta: de todos los clientes que realmente abandonaron, ¿cuántos logró detectar el modelo? En problemas de abandono suele ser una métrica muy relevante porque el negocio quiere identificar a tiempo clientes en riesgo.

Situación	Interpretación
Alto recall	Se detecta la mayoría de clientes que abandonan.
Bajo recall	Muchos abandonos reales no son detectados.

21. F1-score

F1-score combina precision y recall. Es útil cuando se necesita equilibrio entre evitar falsas alarmas y detectar la mayor cantidad posible de casos positivos. Un F1 más alto suele indicar mejor balance entre ambas métricas, aunque siempre debe revisarse junto con la matriz de confusión.

22. ¿Qué métrica priorizar en abandono?

La respuesta depende del objetivo del negocio. Si lo más importante es no dejar escapar clientes en riesgo, se prioriza recall de la clase 1. Si el costo de contactar clientes falsamente alertados es muy alto, precision también cobra importancia. Si se busca equilibrio, se revisa F1-score. Accuracy no debe ser la única métrica.

Objetivo	Métrica sugerida
Detectar la mayor cantidad de abandonos	Recall clase 1
Evitar muchas falsas alarmas	Precision clase 1
Equilibrar detección y calidad de alertas	F1-score clase 1
Medir aciertos generales	Accuracy, con cautela

23. Comparación justa de modelos

Comparar modelos exige usar la misma división de datos, el mismo preprocesamiento y las mismas métricas. Si un modelo usa datos diferentes o recibe más información que otro, la comparación no es válida. Por eso el pipeline ayuda a que cada modelo se pruebe en condiciones equivalentes.

24. Sobreajuste

El sobreajuste ocurre cuando un modelo aprende demasiado bien los datos de entrenamiento, incluso detalles o ruido, y luego falla con datos nuevos. Un árbol de decisión muy profundo puede memorizar casos del entrenamiento. Por eso se limitan parámetros como `max_depth` y se evalúa con conjunto de prueba.

25. Interpretación responsable de resultados

Un modelo no debe presentarse como una verdad absoluta. Debe comunicarse como una herramienta de apoyo. El informe debe incluir qué datos se usaron, qué variables se excluyeron, qué métricas se obtuvieron, qué errores fueron importantes, qué limitaciones existen y por qué la decisión final requiere revisión humana.

26. Uso responsable de IA generativa en esta guía

El aprendizaje puede usar IA generativa para pedir explicación de conceptos, revisar redacción o depurar errores, pero debe declarar su uso y verificar todo. No debe entregar código que no comprende ni conclusiones generadas automáticamente sin análisis propio. La responsabilidad académica recae en el aprendiz.

27. Actividades antes del notebook

Actividad	Producto
Actividad 1	Explique en tres líneas qué es aprendizaje supervisado.
Actividad 2	Construya una tabla con X, y y variables excluidas.
Actividad 3	Dibuje una matriz de confusión y explique FN y FP.
Actividad 4	Defina cuál métrica priorizaría para abandono y justifique.
Actividad 5	Redacte una advertencia ética sobre uso de predicciones.

28. Actividad durante el notebook

- Antes de ejecutar cada bloque, lea el propósito.
- Después de ejecutar, observe el resultado.
- Redacte una interpretación en lenguaje técnico pero comprensible.
- No copie métricas sin explicar qué significan.
- Compare modelos según la necesidad del negocio.

29. Preguntas de cierre

1. ¿Cuál es la diferencia entre entrenar y probar?
2. ¿Por qué no se usa ID_Cliente como predictor?
3. ¿Por qué Abandono no puede estar dentro de X?
4. ¿Qué error representa un falso negativo?
5. ¿Por qué recall puede ser importante en abandono?
6. ¿Por qué el modelo requiere revisión humana?

30. Síntesis final

La Guía 3 no busca que el aprendiz memorice nombres de algoritmos. Busca que comprenda el flujo completo de aprendizaje supervisado: definir la variable objetivo, separar predictoras, dividir entrenamiento y prueba, construir pipeline, entrenar modelos, evaluar métricas, comparar resultados y comunicar conclusiones con límites. El aprendizaje real ocurre cuando el aprendiz puede explicar por qué hizo cada paso y qué significa cada resultado.