

MANUAL TEORICO-PRACTICO DEL APRENDIZ

Guia 3 - Preparacion para aprendizaje supervisado

Procesamiento de datos para modelos de inteligencia artificial

Tema central: clasificacion binaria para prediccion de abandono de clientes.

Version: V4 pedagogica ampliada para estudiantes.

Uso sugerido: leer este manual antes de desarrollar el notebook de la Guia 3. El documento explica los conceptos necesarios, presenta ejemplos de la vida real, incluye formulas, codigo base y ejercicios de comprension.

Tabla de contenido sugerida

1. 1. Proposito del manual
2. 2. Mapa de aprendizaje de la Guia 3
3. 3. Inteligencia artificial, aprendizaje automatico y modelos
4. 4. Aprendizaje supervisado y no supervisado
5. 5. Clasificacion y regresion
6. 6. Caso de estudio: abandono de clientes
7. 7. Variable objetivo y variables predictoras
8. 8. Preparacion previa del dataset
9. 9. Entrenamiento, prueba y fuga de informacion
10. 10. Preprocesamiento con Pipeline y ColumnTransformer
11. 11. Modelos supervisados basicos
12. 12. Prediccion
13. 13. Matriz de confusion
14. 14. Metricas de clasificacion y decision tecnica
15. 15. Comparacion de modelos
16. 16. Interpretacion responsable y limites del modelo
17. 17. Guia para desarrollar el notebook
18. 18. Actividades previas al notebook
19. 19. Plantilla para informe tecnico
20. 20. Glosario practico

1. Proposito del manual

Este manual acompaña la Guía 3 y tiene como finalidad preparar conceptualmente al aprendiz antes de trabajar el notebook de aprendizaje supervisado. No se espera que el aprendiz memorice definiciones, sino que comprenda que un modelo de inteligencia artificial aprende a partir de datos, produce predicciones y debe evaluarse con criterios técnicos.

Idea central

En la Guía 3 no se trata solo de ejecutar código. Se trata de comprender como un dataset preparado puede usarse para entrenar, probar e interpretar un modelo supervisado de clasificación.

Al finalizar la lectura, el aprendiz debería poder responder:

1. Que diferencia hay entre aprendizaje supervisado y no supervisado.
2. Por que el problema de abandono de clientes es un problema de clasificación binaria.
3. Que es una variable objetivo y por que no debe incluirse como predictora.
4. Que significa entrenar y probar un modelo.
5. Por que se debe evitar la fuga de información.
6. Como se interpreta una matriz de confusión.
7. En que casos usar accuracy, precision, recall, F1-score o balanced accuracy.
8. Como comparar modelos sin elegir solo el que tenga mayor accuracy.

2. Mapa de aprendizaje de la Guía 3

Momento	Pregunta que responde	Producto esperado
Comprensión del problema	Que se quiere predecir?	Identificación de la variable objetivo Abandono.
Preparación de variables	Que columnas se usan como entrada?	Separación de X e y, exclusión de ID_Cliente.
División de datos	Como evaluar con datos no vistos?	X_train, X_test, y_train, y_test.
Preprocesamiento	Como tratar numericas, nominales y ordinales?	Pipeline con ColumnTransformer.
Entrenamiento	Como aprende el modelo?	Modelo ajustado con datos de entrenamiento.
Predicción	Que clase predice para datos nuevos?	y_pred generado con X_test.
Evaluación	Que tan bien predice?	Matriz de confusión y metricas.
Comparación	Que modelo responde mejor al problema?	Tabla comparativa y decision tecnica.

3. Inteligencia artificial, aprendizaje automatico y modelos

La inteligencia artificial busca construir sistemas capaces de realizar tareas que requieren algun nivel de razonamiento, reconocimiento de patrones o toma de decisiones asistida. En este programa, la IA se aborda desde el procesamiento de datos: preparar, transformar, seleccionar y documentar datasets que puedan alimentar modelos.

El aprendizaje automatico o Machine Learning es una rama de la IA en la que un sistema aprende patrones a partir de datos historicos. En lugar de programar manualmente todas las reglas, el modelo identifica relaciones entre variables.

Enfoque tradicional	Enfoque con aprendizaje automatico
Se define una regla fija: si dias sin compra > 90, entonces abandono.	El modelo revisa muchos clientes y aprende combinaciones de variables asociadas al abandono.
La regla la escribe una persona.	El patron se aprende desde los datos.
Puede ser rigido ante nuevos casos.	Puede adaptarse mejor si se entrena con datos representativos.

Ejemplo cotidiano

Una persona puede aprender a reconocer si un correo es spam viendo muchos correos anteriores etiquetados como spam y no spam. De forma similar, un modelo puede aprender a identificar clientes con riesgo de abandono observando historicos de clientes que abandonaron y que no abandonaron.

4. Aprendizaje supervisado y no supervisado

La diferencia principal esta en si existe o no una respuesta conocida dentro del dataset.

Tipo de aprendizaje	Tiene respuesta conocida?	Que busca?	Ejemplo de vida real
Supervisado	Si	Predecir una etiqueta o valor conocido.	Predecir si un cliente abandona o no abandona.
No supervisado	No	Encontrar grupos, patrones o estructuras ocultas.	Agrupar clientes segun comportamiento de compra sin saber de antemano el grupo correcto.

4.1 Aprendizaje supervisado

En aprendizaje supervisado, cada registro del dataset tiene variables de entrada y una respuesta conocida. El modelo aprende la relacion entre las entradas y la respuesta.

Edad	QuejasUltimos6M	Satisfaccion	Abandono
25	0	Alta	0
44	3	Baja	1
31	1	Media	0
52	4	Baja	1

En esta tabla, Abandono es la respuesta conocida. El modelo aprende a relacionar características como quejas, satisfaccion y dias desde ultima compra con la clase final.

4.2 Aprendizaje no supervisado

En aprendizaje no supervisado no hay una respuesta conocida. El objetivo no es predecir una etiqueta, sino descubrir patrones.

Edad	ComprasUltimos12M	IngresoMensual	Satisfaccion
25	12	1800	Alta
50	2	7000	Baja
35	8	3200	Media
42	1	2500	Baja

En este caso, el análisis podría buscar segmentos: clientes frecuentes, clientes inactivos, clientes de alto ingreso o clientes sensibles a promociones. No hay columna Abandono para predecir.

5. Clasificación y regresión

Dentro del aprendizaje supervisado existen dos problemas frecuentes: clasificación y regresión.

Tipo de problema	Que predice?	Ejemplo	Salida esperada
Clasificación	Una clase o categoría.	Predecir si un cliente abandona.	0 o 1.
Regresión	Un número continuo.	Predecir el valor de ventas del próximo mes.	Un valor como 1250000.

Por qué la Guía 3 es clasificación

La Guía 3 trabaja con la variable Abandono, que solo tiene dos clases: 0 = no abandona y 1 = abandona. Por eso el problema es de clasificación binaria.

6. Caso de estudio: abandono de clientes

Una empresa desea anticipar que clientes tienen mayor riesgo de abandonar sus servicios. Para ello dispone de datos históricos de clientes: edad, ingresos, compras, quejas, satisfacción, segmento y comportamiento digital. Algunos clientes abandonaron y otros permanecieron.

Situación real	Dato asociado en el dataset	Posible interpretación
Cliente lleva muchos días sin comprar.	DiasDesdeUltimaCompra	Puede existir riesgo de inactividad.
Cliente presentó varias quejas recientes.	QuejasUltimos6M	Puede reflejar insatisfacción.
Cliente reporta satisfacción baja.	Satisfacción	Puede aumentar probabilidad de abandono.
Cliente tiene pocas compras recientes.	ComprasUltimos12M	Puede indicar reducción de relación comercial.

7. Variable objetivo y variables predictoras

La variable objetivo es la columna que se quiere predecir. En esta guía es Abandono. Las variables predictoras son las columnas que el modelo usa para aprender patrones.

Elemento	En la Guía 3	Explicación
Variable objetivo	Abandono	Respuesta que se quiere predecir.
Clase 0	No abandono	Cliente que permaneció.
Clase 1	Abandono	Cliente que se fue o dejó de comprar.
Variables predictoras	Edad, IngresoMensual, QuejasUltimos6M, Satisfacción, etc.	Características usadas para aprender patrones.
Variable excluida	ID_Cliente	Identificador, no comportamiento.

Código base para separar X e y

```
# X contiene las variables predictoras
```

```
# y contiene la variable objetivo
```

```
X = df.drop(columns=["Abandono", "ID_Cliente"])
```

```
y = df["Abandono"]
```

Error comun

No se debe incluir Abandono dentro de X. Si se hace, el modelo recibe la respuesta que debe aprender a predecir. Eso genera fuga de informacion y resultados falsamente buenos.

8. Preparacion previa del dataset

Antes de entrenar un modelo, el dataset debe estar preparado. La Guia 0 trabajo limpieza y transformacion; la Guia 1 trabajo codificacion y escalamiento; la Guia 2 trabajo seleccion de atributos, sesgo y balanceo. La Guia 3 utiliza ese proceso como base para modelamiento supervisado.

Guia	Pregunta principal	Resultado esperado
Guia 0	Los datos estan limpios?	Dataset sin errores basicos, duplicados o formatos incoherentes.
Guia 1	Los datos estan codificados y escalados?	Dataset apto para algoritmos que requieren variables numericas.
Guia 2	Las variables son pertinentes y el dataset esta balanceado o justificado?	Dataset revisado en atributos, sesgo y desbalance.
Guia 3	El dataset permite entrenar y evaluar un modelo supervisado?	Modelo entrenado, evaluado e interpretado.

9. Entrenamiento, prueba y fuga de informacion

Un modelo debe entrenarse con una parte de los datos y evaluarse con otra parte que no haya visto. Esto permite medir si el modelo generaliza y no solo memoriza.

Conjunto	Funcion	Analogía
Entrenamiento	Sirve para que el modelo aprenda patrones.	Material de estudio.
Prueba	Sirve para evaluar con datos no vistos.	Examen sin resolver.

Codigo base

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split(
```

```
    X,
```

```
    y,
```

```
    test_size=0.2,
```

```
    random_state=42,
```

```
stratify=y
```

```
)
```

El parametro stratify=y mantiene una proporcion similar de clases en entrenamiento y prueba. Esto es importante cuando la variable objetivo tiene desbalance.

9.1 Fuga de informacion

La fuga de informacion ocurre cuando el modelo recibe datos que no deberia conocer durante el entrenamiento o cuando se usa informacion del conjunto de prueba para ajustar transformaciones.

Caso incorrecto	Por que esta mal	Forma correcta
Codificar o escalar todo el dataset antes de train_test_split.	El conjunto de prueba influye en el ajuste del transformador.	Separar primero y ajustar solo con entrenamiento.
Incluir Abandono dentro de X.	El modelo recibe la respuesta.	Eliminar Abandono de X y dejarla solo en y.
Balancear todo el dataset antes de separar.	Se altera la distribucion del test.	Balancear solo entrenamiento, si se justifica.

10. Preprocesamiento con Pipeline y ColumnTransformer

Un dataset puede tener variables numericas, categoricas nominales y categoricas ordinales. Cada tipo requiere un tratamiento diferente. Pipeline y ColumnTransformer permiten organizar estas transformaciones de forma segura y reproducible.

Tipo de variable	Ejemplos	Tratamiento recomendado
Numerica	Edad, IngresoMensual, DiasDesdeUltimaCompra	Escalamiento, si el modelo lo requiere.
Categorica nominal	Ciudad, CanalPreferido, ZonaResidencia	One-Hot Encoding.
Categorica ordinal	Segmento, Satisfaccion	OrdinalEncoder respetando el orden.

Errata controlada

Segmento debe tratarse como ordinal: Basico < Medio < Premium. Satisfaccion tambien es ordinal: Baja < Media < Alta. No deben tratarse como variables nominales si se desea conservar el orden.

Codigo base de preprocesamiento

```
from sklearn.compose import ColumnTransformer
```

```
from sklearn.preprocessing import OneHotEncoder, OrdinalEncoder, StandardScaler
```

```
columnas_numericas = ["Edad", "IngresoMensual", "CantidadCompras", "ComprasUltimos12M",  
                      "AntiguedadMeses", "QuejasUltimos6M", "DiasDesdeUltimaCompra",  
                      "VisitasWebUltimoMes", "TiempoPromedioSesionMin", "CuponesUsados"]
```

```

columnas_nominales = ["Ciudad", "CanalPreferido", "ZonaResidencia"]

columnas_ordinales = ["Segmento", "Satisfaccion"]

preprocesador = ColumnTransformer(

    transformers=[

        ("num", StandardScaler(), columnas_numericas),

        ("nom", OneHotEncoder(handle_unknown="ignore"), columnas_nominales),

        ("ord", OrdinalEncoder(categories=[

            ["Basico", "Medio", "Premium"],

            ["Baja", "Media", "Alta"]

        ]), columnas_ordinales)

    ]

)

```

11. Modelos supervisados basicos

La Guia 3 puede usar modelos sencillos para comprender el flujo de aprendizaje supervisado. El objetivo no es convertir al aprendiz en experto matematico de cada algoritmo, sino que comprenda como se entrena, predice, evalua y compara un modelo.

Modelo	Idea sencilla	Ventaja	Cuidado
Regresion logistica	Calcula la probabilidad de pertenecer a una clase.	Buena linea base para clasificacion.	Puede no capturar relaciones complejas.
Arbol de decision	Toma decisiones mediante reglas.	Facil de explicar.	Puede sobreajustar si no se controla.
Random Forest	Combina varios arboles y decide por votacion.	Suele ser robusto.	Puede ser menos interpretable que un arbol simple.

Pipeline con modelo

```

from sklearn.pipeline import Pipeline

from sklearn.linear_model import LogisticRegression

modelo = Pipeline(steps=[

    ("preprocesamiento", preprocesador),

    ("clasificador", LogisticRegression(max_iter=1000, class_weight="balanced"))

])

```


))

```
modelo.fit(X_train, y_train)
```

12. Prediccion

Despues de entrenar, el modelo puede generar predicciones sobre datos que no vio durante el entrenamiento. En la Guia 3 esas predicciones se realizan sobre X_test.

```
y_pred = modelo.predict(X_test)
```

Una prediccion es la clase que el modelo asigna a cada cliente. Si predice 1, significa que identifica riesgo de abandono. Si predice 0, significa que no identifica abandono.

Ciente	Situacion observada	Prediccion posible	Interpretacion
A	Baja satisfaccion, varias quejas, muchos dias sin comprar.	1	Alerta de posible abandono.
B	Alta satisfaccion, compra reciente, sin quejas.	0	Cliente probablemente activo.

13. Matriz de confusion

La matriz de confusion permite ver aciertos y errores del modelo. En clasificacion binaria se organiza en cuatro resultados principales.

	Predijo 0: no abandono	Predijo 1: abandono
Real 0: no abandono	Verdadero negativo (TN)	Falso positivo (FP)
Real 1: abandono	Falso negativo (FN)	Verdadero positivo (TP)

Resultado	Significado en abandono de clientes	Impacto
TP	El cliente abandono y el modelo lo detecto.	Acierto importante.
TN	El cliente no abandono y el modelo lo clasifico bien.	Acierto.
FP	El modelo alerto abandono, pero el cliente no abandono.	Puede generar una accion comercial innecesaria.
FN	El cliente abandono, pero el modelo no lo detecto.	Error delicado: se pierde oportunidad de retencion.

Codigo base

```
from sklearn.metrics import confusion_matrix
```

```
matriz = confusion_matrix(y_test, y_pred)
```

```
print(matriz)
```

14. Metricas de clasificacion y decision tecnica

Las metricas se calculan despues de entrenar el modelo y generar predicciones. No se calculan en la etapa de preparacion del dataset, salvo que se este haciendo una prueba de validacion con modelo.

14.1 Accuracy

Accuracy mide el porcentaje general de aciertos.

Formula

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

Usar accuracy cuando las clases estan relativamente balanceadas y todos los errores tienen un costo similar. No usarla como metrica principal cuando hay desbalance fuerte o cuando detectar la clase minoritaria es lo mas importante.

14.2 Precision

Precision responde: de todos los clientes que el modelo marco como abandono, cuantos realmente abandonaron?

Formula

$$\text{Precision} = TP / (TP + FP)$$

Conviene usar precision cuando las falsas alarmas son costosas. Por ejemplo, si cada alerta genera una llamada, descuento o beneficio economico, no conviene alertar demasiados clientes que no iban a abandonar.

14.3 Recall

Recall responde: de todos los clientes que realmente abandonaron, cuantos detecto el modelo?

Formula

$$\text{Recall} = TP / (TP + FN)$$

Conviene usar recall cuando dejar escapar casos positivos es costoso. En abandono de clientes, un falso negativo puede significar que un cliente en riesgo no recibio ninguna accion de retencion.

14.4 F1-score

F1-score combina precision y recall en una sola medida.

Formula

$$\text{F1-score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$$

Conviene usar F1-score cuando se necesita equilibrio entre detectar abandonos y no generar demasiadas falsas alarmas. No debe interpretarse sin mirar precision y recall por separado.

14.5 Balanced accuracy

Balanced accuracy promedia el recall de cada clase. Es util cuando las clases estan desbalanceadas.

Formula

$$\text{Balanced accuracy} = (\text{Recall clase 0} + \text{Recall clase 1}) / 2$$

Decision sobre metricas

Situacion	Metrica prioritaria	Por que
Clases balanceadas y errores similares.	Accuracy	Resume bien el acierto general.
Clase positiva es importante y no se quiere dejar escapar.	Recall clase 1	Mide cuantos abandonos reales se detectan.
Las alertas positivas son costosas.	Precision clase 1	Mide cuantas alertas positivas son correctas.
Se necesita equilibrio entre precision y recall.	F1-score clase 1	Integra ambas metricas.
Hay desbalance y se quiere evaluar ambas clases.	Balanced accuracy	Evita que la clase mayoritaria oculte errores.

Codigo base de metricas

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, balanced_accuracy_score, classification_report
```

```
print("Accuracy:", accuracy_score(y_test, y_pred))

print("Precision clase 1:", precision_score(y_test, y_pred, pos_label=1))

print("Recall clase 1:", recall_score(y_test, y_pred, pos_label=1))

print("F1 clase 1:", f1_score(y_test, y_pred, pos_label=1))

print("Balanced accuracy:", balanced_accuracy_score(y_test, y_pred))

print(classification_report(y_test, y_pred))
```

15. Comparacion de modelos

Comparar modelos significa evaluar varias alternativas bajo las mismas condiciones de datos y metricas. No se debe seleccionar un modelo solo porque tiene mayor accuracy. La decision depende del objetivo del problema.

Modelo	Accuracy	Precision clase 1	Recall clase 1	F1 clase 1	Decision
Regresion logistica	0.78	0.52	0.70	0.60	Buena deteccion de abandono.
Arbol de decision	0.80	0.58	0.50	0.54	Mas aciertos generales, pero menor recall.
Random Forest	0.82	0.63	0.61	0.62	Equilibrio razonable.

En un problema de abandono, si la prioridad es detectar clientes en riesgo, se debe mirar especialmente recall y F1-score de la clase 1. Si la prioridad es reducir falsas alarmas, se debe mirar precision de la clase 1.

16. Interpretacion responsable y limites del modelo

Un modelo de IA no reemplaza la decision humana. Sus resultados deben interpretarse como apoyo tecnico para analizar riesgos, priorizar acciones y orientar decisiones. El modelo puede equivocarse, especialmente si los datos tienen sesgos, baja calidad, desbalance o variables poco representativas.

Riesgo	Ejemplo	Accion responsable
Sesgo de datos	Pocos registros de una zona o segmento.	Reportar limitacion y no generalizar.
Falsa seguridad por accuracy alta	Modelo acierta la clase mayoritaria pero falla en abandono.	Revisar recall y F1 clase 1.
Fuga de informacion	Abandono queda dentro de X.	Separar correctamente variables.
Uso automatico de predicciones	Negar beneficios solo por prediccion.	Exigir revision humana y contexto.

17. Guia para desarrollar el notebook

El notebook debe desarrollarse como una secuencia de aprendizaje, no como una coleccion de codigo. Cada bloque debe tener una explicacion, codigo, resultado y analisis.

Bloque del notebook	Que se hace	Que se debe analizar
Carga de datos	Leer el archivo CSV.	Verificar filas, columnas y estructura.
Variable objetivo	Identificar Abandono.	Confirmar que es binaria.
Separacion X e y	Excluir Abandono e ID_Cliente.	Evitar fuga de informacion.
Train-test split	Dividir entrenamiento/prueba.	Mantener proporcion de clases con stratify.
Preprocesamiento	Configurar columnas numericas, nominales y ordinales.	Respetar orden de Segmento y Satisfaccion.
Modelo	Entrenar uno o varios clasificadores.	Comprender fit y predict.
Metricas	Calcular matriz de confusion y classification_report.	Interpretar clase 1.
Comparacion	Comparar modelos.	Justificar decision tecnica.

18. Actividades previas al notebook

Antes de ejecutar codigo, se recomienda resolver estas actividades en el cuaderno o en una hoja de trabajo.

1. Explique con sus palabras la diferencia entre aprendizaje supervisado y no supervisado.
2. Indique por que Abandono es una variable objetivo.
3. Clasifique el problema como clasificacion o regresion y justifique.
4. Liste tres variables que podrian ayudar a predecir abandono y explique por que.
5. Explique por que ID_Cliente no debe usarse como predictor.
6. Explique que podria pasar si Abandono queda dentro de X.

7. Explique que metrica priorizaria si la empresa desea detectar la mayor cantidad posible de clientes que abandonan.
8. Explique que metrica priorizaria si cada alerta de abandono genera un descuento costoso.

19. Plantilla para informe tecnico

Seccion	Contenido esperado
Descripcion del problema	Explicar que se busca predecir abandono de clientes.
Descripcion del dataset	Filas, columnas, variable objetivo y variables predictoras.
Preparacion de datos	Separacion X/y, train-test split, preprocesamiento.
Modelo entrenado	Modelo o modelos utilizados.
Resultados	Matriz de confusion, accuracy, precision, recall, F1.
Interpretacion	Analisis de desempeno sobre clase 1.
Decision tecnica	Modelo seleccionado y justificacion.
Limitaciones	Sesgo, desbalance, datos sinteticos o alcance del modelo.
Conclusion	Sintesis del proceso y uso responsable.

20. Glosario practico

Termino	Definicion sencilla
Aprendizaje supervisado	Modelo aprende con ejemplos que ya tienen respuesta.
Aprendizaje no supervisado	Modelo busca patrones sin una respuesta conocida.
Clasificacion	Prediccion de una categoria o clase.
Regresion	Prediccion de un valor numerico continuo.
Variable objetivo	Columna que se quiere predecir.
Variables predictoras	Columnas usadas para aprender patrones.
Entrenamiento	Proceso en el que el modelo aprende.
Prueba	Datos no vistos usados para evaluar.
Fuga de informacion	Uso indebido de informacion que el modelo no deberia conocer.
Pipeline	Flujo ordenado de preprocesamiento y modelo.
Matriz de confusion	Tabla de aciertos y errores del modelo.
Accuracy	Porcentaje general de aciertos.
Precision	Confiabilidad de las predicciones positivas.
Recall	Capacidad para detectar los positivos reales.
F1-score	Equilibrio entre precision y recall.

Cierre del manual

Mensaje final para el aprendiz

Antes de entrenar un modelo, es necesario comprender que se quiere predecir, que datos se usaran, como se evita la fuga de informacion y como se interpretaran los resultados. Un modelo no es bueno solo porque entrega una metrica alta; debe responder al problema, detectar adecuadamente la clase importante y ser interpretado con responsabilidad.