

Manual teórico del estudiante - Guía 5

Documentación técnica, validación y sustentación del proceso de datos

Programa: Procesamiento de datos para modelos de inteligencia artificial

Proyecto formativo: Construcción de datasets para ser empleados en modelos de inteligencia artificial

1. ¿Qué es documentar un proceso de datos?

Documentar un proceso de datos es dejar una evidencia organizada de las acciones realizadas sobre un dataset. La documentación permite que otra persona comprenda el origen de los datos, los problemas encontrados, las transformaciones aplicadas, los resultados obtenidos y las limitaciones existentes.

Un proceso técnico sin documentación puede funcionar una vez, pero es difícil de revisar, corregir, mejorar o reutilizar. Por eso, la documentación es parte del producto, no un accesorio.

2. Trazabilidad

La trazabilidad responde a la pregunta: ¿cómo llegó el dataset desde su estado inicial hasta la versión final? Para lograrla se deben conservar nombres de archivos, versiones, decisiones técnicas y evidencias de validación.

Ejemplo: base_original.csv -> limpieza -> codificación -> escalamiento -> dataset_preparado.csv -> modelo/evaluación -> informe_final.pdf.

3. Reproducibilidad

Un proceso es reproducible cuando otra persona puede ejecutar el notebook o script y obtener resultados equivalentes. Para esto se requieren rutas claras, librerías necesarias, orden lógico de ejecución y datos disponibles.

La reproducibilidad no exige que todos los resultados aleatorios sean idénticos siempre, pero sí exige que el flujo pueda ejecutarse sin depender de pasos ocultos.

4. Validación final del dataset

Antes de entregar un dataset se deben revisar dimensiones, columnas, tipos de dato, valores nulos, duplicados, variables objetivo, identificadores y consistencia de categorías.

Validar no es modificar al azar. Validar es comprobar que el producto final cumple condiciones mínimas para ser usado e interpretado.

5. Informe técnico

El informe técnico comunica el proceso en lenguaje formal. Debe explicar el problema, el dataset, la metodología, las transformaciones, los resultados, las limitaciones y las recomendaciones.

El informe no debe ser una colección de pantallazos. Debe interpretar las evidencias y justificar las decisiones.

6. Sustentación técnica

La sustentación es la explicación oral del proceso. El aprendiz debe poder responder por qué seleccionó variables, por qué codificó o escaló, por qué balanceó o no balanceó, qué métrica usó, qué resultados obtuvo y qué limitaciones encontró.

Una buena sustentación no consiste en leer diapositivas, sino en demostrar dominio del proceso.

7. Errores frecuentes

Entregar solo el notebook sin informe, no explicar las transformaciones, usar rutas absolutas que no funcionan en otro equipo, no declarar el uso de IA, no interpretar las métricas, usar la variable objetivo como predictor o no adjuntar el dataset usado.

Otro error común es presentar los resultados como verdades absolutas. Todo modelo y todo dataset tienen supuestos, limitaciones y riesgos.

8. Estructura recomendada del informe técnico

Sección	Contenido esperado
Portada	Datos institucionales, aprendiz, ficha, guía y fecha.
Introducción	Propósito del proceso y contexto del problema.
Descripción del dataset	Origen, tamaño, variables, objetivo y alcance.
Diagnóstico inicial	Nulos, duplicados, tipos, outliers y calidad inicial.
Transformaciones	Limpieza, codificación, escalamiento, balanceo o clustering.
Validación	Pruebas de consistencia y resultados de la revisión técnica.
Resultados	Métricas, gráficas, clusters, perfiles o predicciones.
Interpretación	Qué significan los resultados para el problema.
Limitaciones	Aspectos que restringen la confianza o aplicación.
Recomendaciones	Mejoras futuras y acciones sugeridas.
Declaración de IA	Uso transparente y responsable de herramientas de IA.

9. Lista mínima de control

- ☐ El dataset final abre correctamente.
- ☐ El notebook ejecuta en orden.
- ☐ Las rutas de archivos son comprensibles.
- ☐ El diccionario de datos está completo.
- ☐ Las gráficas tienen título e interpretación.
- ☐ Las métricas están justificadas.
- ☐ El informe tiene conclusiones y limitaciones.
- ☐ Se declara el uso de IA.