

1. Propósito de aprendizaje

Al finalizar esta guía, el aprendiz integrará datos provenientes de archivos CSV, libros de Excel, archivos JSON y una base de datos relacional SQLite, aplicando controles básicos de calidad, llaves de unión, agregaciones y trazabilidad para construir un dataset integrado útil para análisis, indicadores o preparación posterior para IA.

2. Alineación curricular

La guía se alinea con los resultados de aprendizaje de la competencia Integrar Datos: preparar datos según fuentes de información, alistar datos para una solución IA, procesar datos con metodología estadística y presentar resultados mediante técnicas de visualización. En esta guía se excluye el trabajo con bases NoSQL para evitar duplicidad y mantener el enfoque en fuentes estructuradas y relacionales.

Elemento	Descripción
RAP principal	RAP 2: Alistar datos para una solución IA según técnicas de tratamiento de datos y la necesidad del negocio.
RAP relacionados	RAP 1: Preparar datos según fuentes de información. RAP 3: Procesar datos según metodología estadística. RAP 4: Presentar datos con visualización.
Evidencia principal	Dataset integrado, notebook ejecutado e informe de integración.
Herramientas	Python, Pandas, SQLite, Jupyter Notebook, Excel/CSV/JSON y Matplotlib.

3. Situación problema

Una empresa tiene información de clientes distribuida en distintas fuentes: un archivo CSV con datos maestros de clientes, un Excel con compras, un JSON con interacciones web y una base relacional SQLite con satisfacción y quejas. La dirección necesita un dataset único para analizar comportamiento comercial, construir indicadores y preparar insumos para futuros modelos de IA.

4. Fuentes de datos de la actividad

Fuente	Archivo	Contenido	Llave de integración
CSV	clientes.csv	Datos maestros del cliente: edad, ciudad, segmento, canal preferido y fecha de registro.	ID_Cliente
Excel	compras.xlsx	Transacciones: fecha, categoría, cantidad, valor unitario y descuento.	ID_Cliente
JSON	interacciones_web.json	Visitas web, tiempo de sesión y fuente web.	ID_Cliente
SQL relacional	empresa_integracion.db	Tabla satisfaccion_clientes con satisfacción y quejas.	ID_Cliente

5. Ruta de trabajo por sesiones

Sesión	Tema	Actividad guiada	Producto
Sesión 1	Comprender el problema de integración	Reconocer fuentes, llaves, granularidad y producto esperado.	Mapa de fuentes y llaves.
Sesión 2	Carga y diagnóstico de fuentes	Cargar CSV, Excel, JSON y SQL; revisar dimensiones, tipos, duplicados y nulos.	Diagnóstico inicial.
Sesión 3	Normalización y preparación de llaves	Estandarizar ID_Cliente, fechas, nombres de columnas y formatos.	Fuentes preparadas.
Sesión 4	Agregación de compras e integración	Agrupar transacciones por cliente y unir con fuentes maestras.	Dataset integrado preliminar.
Sesión 5	Validación y trazabilidad	Verificar cobertura, duplicados, consistencia y registros sin correspondencia.	Reporte de validación.
Sesión 6	Indicadores, visualización e informe	Generar indicadores, gráficas y conclusiones del proceso.	Informe de integración.

6. Actividad central

Nombre de la actividad: Construcción de un dataset integrado desde múltiples fuentes estructuradas.

Instrucciones para el aprendiz:

Descargar y organizar los cuatro archivos fuente en la carpeta 03_data.

Ejecutar el notebook de integración en orden, sin saltar celdas.

Identificar la llave común entre fuentes y justificar su uso.

Realizar diagnóstico inicial de cada fuente: filas, columnas, tipos, nulos y duplicados.

Agrupar las compras por cliente antes de unir las al dataset maestro.

Integrar todas las fuentes usando ID_Cliente.

Validar registros sin correspondencia, duplicados y campos críticos.

Exportar el dataset integrado final.

Elaborar el informe de integración con hallazgos, limitaciones y recomendaciones.

7. Entregables

Entregable	Formato	Descripción
Notebook de integración	.ipynb	Proceso completo de carga, diagnóstico, integración y validación.
Dataset integrado	.csv	Archivo final con una fila por cliente.
Reporte de calidad	.txt/.pdf	Resumen de nulos, duplicados, cobertura de fuentes y registros no integrados.
Gráficas	.png o dentro del notebook	Visualizaciones de indicadores básicos.
Informe de integración	.pdf	Documento técnico con metodología, resultados y conclusiones.
Lista de chequeo	.docx/.pdf	Validación de cumplimiento de criterios.

8. Criterios de evaluación

Criterio	Qué se espera
Comprensión del problema	Reconoce las fuentes, la llave común y la necesidad del negocio.
Carga de fuentes	Carga correctamente CSV, Excel, JSON y SQL relacional.
Diagnóstico de calidad	Identifica nulos, duplicados, tipos de datos y registros sin correspondencia.
Integración	Construye un dataset único con una fila por cliente y variables agregadas.
Validación	Verifica consistencia, cobertura, duplicados y trazabilidad.
Comunicación	Presenta resultados mediante gráficas, tablas e informe técnico claro.

9. Uso responsable de IA

El aprendiz puede usar inteligencia artificial para mejorar redacción, organizar el informe o aclarar conceptos, pero debe declarar su uso y verificar personalmente el código, las uniones, los resultados y las conclusiones.