

1. ¿Qué es integrar datos?

Integrar datos consiste en combinar información proveniente de diferentes fuentes para construir una vista unificada, coherente y útil. No se trata solo de pegar tablas, sino de comprender qué representa cada fuente, cuál es su nivel de detalle, qué llave permite unirlos y qué reglas se deben aplicar para evitar errores.

2. Conceptos esenciales

Concepto	Explicación	Ejemplo
Fuente de datos	Lugar o archivo donde se encuentra la información.	CSV de clientes, Excel de compras, JSON web, tabla SQL.
Llave de unión	Campo común que permite relacionar registros entre fuentes.	ID_Cliente.
Granularidad	Nivel de detalle de una tabla.	Clientes: una fila por cliente. Compras: varias filas por cliente.
Dato maestro	Entidad principal relativamente estable.	Cliente.
Dato transaccional	Registro de eventos o movimientos.	Compra realizada.
Dataset integrado	Tabla final que consolida variables de varias fuentes.	Una fila por cliente con compras, satisfacción e interacción web.

3. Tipos de fuentes usadas en esta guía

3.1 CSV

Un CSV es un archivo de texto estructurado por filas y columnas. Es común para exportar datos desde sistemas operativos, formularios o plataformas comerciales.

3.2 Excel

Excel se usa frecuentemente para registrar datos operativos. En integración, se debe revisar la hoja correcta, encabezados, formatos de fecha y valores numéricos.

3.3 JSON

JSON organiza datos como pares clave-valor. Es común en APIs y aplicaciones web. En Pandas puede leerse como registros para convertirlo en DataFrame.

3.4 SQL relacional

Una base relacional organiza la información en tablas conectadas por llaves. En esta guía se usa SQLite para practicar consultas sin instalar un servidor.

4. Ruta técnica de integración

Paso	Acción	Por qué importa
1	Cargar cada fuente	Permite revisar estructura y disponibilidad de datos.
2	Diagnosticar calidad	Evita integrar errores sin conocerlos.
3	Normalizar nombres y formatos	Reduce errores de unión y lectura.
4	Revisar llaves	Confirma que las fuentes se pueden relacionar.
5	Agrupar transacciones	Evita duplicar clientes al unir compras.
6	Unir fuentes	Construye la vista consolidada.

Paso	Acción	Por qué importa
7	Validar resultado	Comprueba consistencia y trazabilidad.
8	Exportar e informar	Permite usar el dataset y documentar decisiones.

5. ¿Por qué no se une todo directamente?

Porque las fuentes pueden tener distinta granularidad. Si la tabla de clientes tiene una fila por cliente y la tabla de compras tiene varias filas por cliente, unir las directamente puede multiplicar filas. Por eso primero se agregan compras por cliente, calculando variables como total de compras, total vendido y última compra.

6. Joins relacionales básicos

Tipo de unión	Uso	Ejemplo en la guía
LEFT JOIN	Conservar todos los clientes aunque no tengan datos en otra fuente.	Clientes + compras agregadas.
INNER JOIN	Conservar solo registros con coincidencia en ambas fuentes.	Validar clientes con compras.
ANTI JOIN conceptual	Detectar registros que no tienen correspondencia.	Compras con ID_Cliente inexistente.

7. Errores frecuentes en integración

Usar una llave incorrecta o con espacios.

No revisar registros duplicados.

Unir datos transaccionales sin agregarlos.

No convertir fechas antes de calcular recencia.

No validar registros sin correspondencia.

Exportar el dataset final sin revisar filas, columnas y nulos.

8. Buenas prácticas

Conservar copia de las fuentes originales.

Documentar cada transformación.

Usar nombres de columnas claros.

Validar el número de filas antes y después de cada unión.

Separar el diagnóstico de la transformación.

Generar un reporte de calidad final.

9. Uso de IA en la documentación

La IA puede ayudar a explicar hallazgos y mejorar redacción, pero no debe reemplazar la validación técnica. El aprendiz debe comprobar que los datos fueron cargados, unidos, agregados y exportados correctamente.